



Entendiendo los Datos

Entrega 2

Integrantes:

Irasema Álvarez Treviño - A01286449
Miguel Ángel Hernández Ochoa - A00830949
Eugenio Moreno Vargas - A01723720
Natalia Ixchel Reynoso Ramírez - A01352603
Abraham Vicente González - A01199401

Materia: Aplicación de Métodos Multivariados en Ciencia de Datos (Gpo. 101)

Socio formador: SIMA (Sistema Integral de Monitoreo Ambiental)

Profesores: Blanca Rosa Ruiz Hernández — Raúl Gómez Muñoz

Fecha: 27 de agosto de 2026

ITESM

Índice

1. Objetivo del Análisis	2
2. Técnicas Estadísticas Propuestas	2
3. Comprensión de los Datos	3
3.1. Continuidad respecto a la Etapa 1	3
3.2. Dimensión del Dataset	3
3.3. Descripción de las Variables	3
3.4. Exploración de Datos	3
3.4.1. Medidas Estadísticas — Variables Cuantitativas	3
3.4.2. Medidas Estadísticas — Variables Cualitativas	4
3.4.3. Visualización — Variables Cuantitativas	4
3.4.4. Visualización — Variables Categóricas	5
4. Verificación de la Calidad de los Datos	5
5. Variables Elegidas y sus Características Estadísticas	5
6. Resumen	6
7. Anexos	7
8. Declaratoria de uso de IA	8
9. Acceso a la Base de Datos y Código	9

1. Objetivo del Análisis

El objetivo de nuestro análisis se redefinió para estudiar la relación entre las concentraciones de ozono troposférico (O_3) y las partículas $PM_{2,5}$ y PM_{10} en el Área Metropolitana de Monterrey, considerando la influencia de variables meteorológicas como la temperatura, radiación solar, humedad, precipitación y viento. Inicialmente, el proyecto buscaba analizar de manera general cómo las condiciones climáticas influyen en los distintos contaminantes; sin embargo, a partir de las necesidades expresadas por SIMA y de la revisión bibliográfica, decidimos enfocarnos en el comportamiento del ozono, particularmente en investigar por qué algunos períodos con bajas concentraciones de partículas coinciden con mayores niveles de O_3 . Este cambio permite abordar una problemática más específica y relevante para Monterrey, donde las condiciones meteorológicas y las emisiones de una zona altamente urbanizada e industrializada pueden favorecer dinámicas complejas de formación y transporte de ozono, y cuyos resultados podrían aportar al socio formador (SIMA) información útil para comprender, comunicar y anticipar episodios de mala calidad del aire.

De este modo, se reitera el objetivo del análisis llevado a cabo: ¿Qué relación existe entre la disminución de las concentraciones de partículas $PM_{2,5}$ y PM_{10} y el aumento de las concentraciones de ozono (O_3), y bajo qué condiciones meteorológicas se presenta con mayor frecuencia este comportamiento?

2. Técnicas Estadísticas Propuestas

- **Análisis descriptivo y exploratorio (EDA)**. Se calcularán medidas como media, mediana, desviación estándar, percentiles, mínimos y máximos para O_3 , $PM_{2,5}$, PM_{10} y

las variables meteorológicas. También será importante analizar series de tiempo y promedios móviles, especialmente para el O_3 . Esto permitirá identificar horas, días, temporadas y estaciones de monitoreo con comportamientos particulares. El uso de percentiles, máximos diarios y promedios móviles de ocho horas está respaldado por los indicadores utilizados por SINAICA/SCICA.

- **Análisis de correlación.** Será una de las técnicas centrales para cuantificar la dirección y fuerza de las relaciones entre O_3 , $PM_{2,5}$, PM_{10} , temperatura, humedad, precipitación, viento y radiación solar. En particular, permitirá comprobar si existe estadísticamente la relación inversa observada por SIMA —menores partículas y mayor ozono— y cuáles variables meteorológicas presentan mayor asociación con el O_3 . En el estudio explorado en la revisión bibliográfica de Islam et al. (2023), se utilizaron correlaciones similares para estudiar la relación entre partículas y condiciones meteorológicas.
- **Análisis de Componentes Principales (PCA).** Debido a que se trabajará simultáneamente con numerosos contaminantes y variables meteorológicas relacionadas entre sí, PCA permitirá reducir la dimensionalidad e identificar combinaciones de variables que expliquen la mayor variabilidad de los datos.
- **Regresión múltiple.** Se puede construir un modelo tomando la concentración de O_3 como variable respuesta y $PM_{2,5}$, PM_{10} y las variables meteorológicas como variables explicativas. Esto permitirá estimar qué variables tienen una asociación significativa con los cambios en el ozono y cuánto de su variabilidad puede explicarse conjuntamente. La revisión bibliográfica proporciona un antecedente directo: Islam et al. (2023) utilizaron regresión no lineal múltiple para eva-

luar el efecto conjunto de variables meteorológicas sobre las partículas.

3. Comprensión de los Datos

3.1. Continuidad respecto a la Etapa 1

La base utilizada en esta etapa parte directamente de los archivos limpios generados en la Etapa 1 (formato `parquet`, uno por variable: O3, PM2.5, PM10, SR y TOUT), en los que ya se habían aplicado los rangos operativos válidos según los criterios del SIMA y la separación por variable y estación de monitoreo. Dado que el objetivo de esta fase se redefinió para enfocarse en la relación entre ozono troposférico (O₃), partículas suspendidas (PM2.5 y PM10) y variables meteorológicas asociadas a su formación fotoquímica (radiación solar y temperatura exterior), no se utilizan en este análisis los atributos derivados de viento ni los rezagos temporales construidos en la Etapa 1, ya que no son relevantes para el objetivo actual; estos podrán retomarse en etapas posteriores si el modelo lo requiere.

Para construir el subconjunto de trabajo, las cinco tablas limpias se integraron mediante un `inner join` secuencial sobre las llaves `Date` y `Estacion`, y posteriormente se eliminaron los registros con valores nulos remanentes y los duplicados exactos en (`Date`, `Estacion`). Este procedimiento garantiza que cada fila del dataset final contenga una medición simultánea y completa de las cinco variables para una estación y hora determinadas.

3.2. Dimensión del Dataset

Antes de la integración, cada variable contaba con un número distinto de registros válidos (desde 564,250 en PM2.5 hasta 725,814 en

SR), reflejo de las distintas tasas de datos faltantes por sensor. Tras el `inner join` y la eliminación de nulos y duplicados, el dataset final de trabajo quedó conformado por 456,519 registros y 7 columnas: `Date`, `Estacion` y las cinco variables numéricas (O3, PM2.5, PM10, SR, TOUT), distribuidas en 15 estaciones de monitoreo.

3.3. Descripción de las Variables

Var.	Descripción	Tipo	Valores posibles	Nul.
Date	Fecha y hora de medición	Fecha	Rango continuo	0 %
Estacion	Estación de monitoreo SIMA	Categoría	15 estaciones: CE, NE, NE2, NE3, NO, NO2, NO3, NTE, NTE2, SE, SE2, SE3, SO, SO2 y SUR	0 %
O ₃	Ozono troposférico	Continua	0–183 ppb (aprox.)	0 %
PM _{2,5}	Partículas $\leq 2,5 \mu\text{m}$	Continua	Valores positivos; valores atípicos extremos	0 %
PM ₁₀	Partículas $\leq 10 \mu\text{m}$	Continua	Valores positivos; valores atípicos extremos	0 %
SR	Radiación solar	Continua	0–1.25 (aprox.)	0 %
TOUT	Temperatura exterior	Continua	–3 a 48 °C (aprox.)	0 %

Cuadro 1: Variables del conjunto integrado tras la limpieza. El porcentaje de nulos se calculó sobre el conjunto depurado.

3.4. Exploración de Datos

3.4.1. Medidas Estadísticas — Variables Cuantitativas

Con base en el método de rango intercuartílico (IQR), la proporción de valores atípicos oscila entre 0.88 % (TOUT) y 5.23 % (SR). Destaca que el rango de PM2.5 (999) y de PM10 (997) es notablemente mayor que el de sus respectivos IQR (15.88 y 38.00), lo que

Variable	Promedio	Mediana	Moda	Desv. Est.	Rango	Q1	Q3	IQR	Outliers (%)
O3	27.22	23.00	16.0	19.25	183.00	13.00	37.00	24.00	2.75
PM2.5	20.40	17.00	10.0	15.32	999.00	10.47	26.35	15.88	3.70
PM10	60.92	52.00	39.0	40.80	997.00	36.00	74.00	38.00	4.76
SR	0.15	0.01	0.0	0.22	1.25	0.00	0.25	0.25	5.23
TOUT	23.59	24.22	24.4	7.00	51.12	19.18	28.45	9.27	0.88

Cuadro 2: Medidas de tendencia central y dispersión, $N = 456,519$ para todas las variables

sugiere la presencia de valores extremos puntuales que se documentan con más detalle en la Sección 4.

3.4.2. Medidas Estadísticas — Variables Cualitativas

La única variable cualitativa relevante para este análisis es *Estacion*. La tabla de distribución de frecuencias es la siguiente:

Estación	Conteo	% Relativo
CE	42,013	9.20
NE	27,433	6.01
NE2	27,554	6.04
NE3	1,992	0.44
NO	18,208	3.99
NO2	33,215	7.28
NO3	3,378	0.74
NTE	30,703	6.73
NTE2	38,189	8.37
SE	41,044	8.99
SE2	34,780	7.62
SE3	42,557	9.32
SO	41,098	9.00
SO2	42,889	9.39
SUR	31,466	6.89

Cuadro 3: Distribución de frecuencia de registros válidos por estación de monitoreo

La distribución es marcadamente desigual: las estaciones NE3 y NO3 aportan menos del 1 % de los registros cada una, mientras que ocho estaciones (CE, NTE2, SE, SE2, SE3, SO, SO2 y SUR) concentran entre el 6.9 % y el 9.4 % cada una. Esta heterogeneidad debe

considerarse al interpretar resultados agregados, pues las estaciones con menor representación (NE3, NO3, NO) podrían aportar menos evidencia estadística confiable.

3.4.3. Visualización — Variables Cuantitativas

Los boxplots por estación (Figura 1) muestran diferencias visibles en el nivel típico y la dispersión de O₃, PM2.5 y PM10 entre estaciones, consistente con la heterogeneidad espacial esperada en una red de monitoreo urbana.

Los histogramas con curva de densidad (Figura 2) muestran que las tres variables de contaminantes presentan asimetría positiva (cola larga hacia la derecha), es decir, la mayoría de las observaciones se concentran en valores bajos-medios con episodios ocasionales de concentraciones altas. En los tres casos la media se ubica por encima de la mediana, lo cual es consistente con dicha asimetría.

El mapa de calor de correlación de Pearson (Figura 3) revela dos relaciones principales: (1) O₃ correlaciona positiva y moderadamente con radiación solar ($r = 0,53$) y temperatura ($r = 0,49$), consistente con su mecanismo de formación fotoquímica; y (2) PM2.5 y PM10 correlacionan fuertemente entre sí ($r = 0,61$), lo esperado dado que ambas miden material particulado de distinto tamaño proveniente de fuentes similares. En contraste, la correlación entre O₃ y los contaminantes de partículas es prácticamente nula ($r \approx 0,01$ con PM2.5 y PM10), lo que sugiere

procesos de formación distintos y en ocasiones antagónicos (el O_3 se consume en presencia de altas concentraciones de NO_x asociadas a fuentes de partículas).

El diagrama de dispersión de $PM_{2.5}$ vs. O_3 coloreado por radiación solar (Figura 5) refuerza este hallazgo: no se observa una tendencia lineal clara entre $PM_{2.5}$ y O_3 ($r = 0,008$), pero sí se aprecia que las concentraciones más altas de O_3 tienden a coincidir con niveles altos de radiación solar, independientemente del nivel de $PM_{2.5}$.

3.4.4. Visualización — Variables Categóricas

La Figura 4 muestra el número de registros válidos por estación en un diagrama de barras horizontales, confirmando de forma visual la desigualdad en representación descrita en la Sección 3.4.2: las estaciones NE3 y NO3 destacan por tener muchos menos registros que el resto.

4. Verificación de la Calidad de los Datos

La integración de las cinco tablas limpias de la Etapa 1 mediante `inner join` sobre (`Date`, `Estacion`), seguida de `dropna()` y eliminación de duplicados, redujo el número de registros de un máximo de 725,814 (variable `SR`) a 456,519 filas finales —una reducción de aproximadamente 37 %—. Esta pérdida se debe principalmente a que el `inner join` exige que las cinco variables tengan una medición simultánea válida para la misma estación y hora exacta; cuando cualquiera de los cinco sensores falla en un instante dado, la observación completa se descarta. No se generó una matriz de nulos sobre el dataset final porque, por construcción del `dropna()`, éste queda con 0 % de valores faltantes; el análisis de faltantes es más informativo si se aplica

antes de la integración, comparando el conteo de horas válidas de cada archivo `parquet` original contra el total teórico de horas del periodo de estudio (se recomienda añadir esta comparación, por variable y estación, como visualización de barras o mapa de calor en los Anexos si no se realizó ya en la Etapa 1).

Un hallazgo adicional de calidad detectado en esta etapa es el valor máximo de $PM_{2.5}$ (rango total de 999) y de PM_{10} (rango total de 997), muy por encima de sus respectivos rangos intercuartílicos (15.88 y 38.00). Valores de exactamente 999 o cercanos a él son un patrón típico de códigos de error o de "dato no disponible" mal codificados como valor numérico en estaciones de monitoreo ambiental, en lugar de haberse limpiado como `NaN`. Se recomienda revisar explícitamente si existen observaciones con $PM_{2.5}$ o PM_{10} iguales o cercanos a 999/997 y, de confirmarse como códigos de error, eliminarlas o imputarlas antes de continuar con el modelado, en lugar de tratarlas únicamente como outliers estadísticos del IQR.

No se detectaron registros duplicados adicionales tras el `drop_duplicates` sobre (`Date`, `Estacion`), y las 15 estaciones se mantuvieron consistentes en nombre y formato a lo largo de las cinco fuentes integradas, sin errores de escritura visibles.

5. Variables Elegidas y sus Características Estadísticas

Para cumplir el objetivo de analizar la relación entre ozono troposférico, partículas suspendidas y condiciones meteorológicas, se seleccionaron las siguientes variables:

- **O_3 (ozono troposférico):** variable de interés principal. Presenta asimetría positiva, media de 27.22 ppb y mediana

de 23.00 ppb, con un 2.75 % de valores atípicos según IQR. Su correlación positiva con SR y TOUT ($r = 0,53$ y $r = 0,49$ respectivamente) la posiciona como la variable más ligada a condiciones meteorológicas de entre las tres estudiadas.

- **PM2.5 y PM10:** variables de material particulado, fuertemente correlacionadas entre sí ($r = 0,61$), pero con una relación débil o nula con O_3 ($r \approx 0,01$). Ambas requieren revisión adicional de calidad por los valores extremos señalados en la Sección 4.
- **SR (radiación solar) y TOUT (temperatura exterior):** variables meteorológicas explicativas, seleccionadas por su relación fisicoquímica directa con la formación de O_3 (fotoquímica dependiente de luz solar y temperatura).
- **Estacion:** variable categórica indispensable para el análisis, ya que actúa como proxy de ubicación geográfica y contexto de emisión local. Las 15 estaciones no son equivalentes en representatividad (desde 0.44 % hasta 9.39 % de los registros) ni en el patrón de correlación O_3 -PM (que varía de $-0,31$ en NE3 a $+0,26$ en SUR), por lo que cualquier modelo agregado debería considerar el efecto de estación, ya sea como variable de control o mediante análisis estratificado.

6. Resumen

Logros hasta el momento

- Se integraron las cinco fuentes limpias de la Etapa 1 en un único dataset de 456,519 registros y 7 columnas mediante `inner join` y eliminación de nulos y duplicados.

- Se calcularon las medidas estadísticas de tendencia central, dispersión y outliers para las variables cuantitativas, además de la distribución de frecuencias de la variable categórica **Estacion**.
- Se generaron visualizaciones (boxplots, histogramas con KDE, mapa de calor de correlación, gráfico de barras y diagrama de dispersión) que permiten identificar la relación esperada entre O_3 y las variables meteorológicas, así como la ausencia de una relación lineal fuerte entre O_3 y PM2.5/PM10.
- Se detectó un posible problema de calidad de datos asociado a valores extremos de 999 y 997 en PM2.5 y PM10, los cuales requieren revisión antes de avanzar al modelado.

Pendientes

- Confirmar y tratar los valores sospechosos de PM2.5 y PM10 identificados en la Sección 4.
- Profundizar el análisis de faltantes previo a la integración, tanto por variable como por estación.
- Explorar si la relación entre O_3 y las variables meteorológicas varía de forma sistemática por estación o por periodo, considerando por ejemplo la estacionalidad diaria o anual, lo cual podría orientar el tipo de modelo a construir en la siguiente etapa.

Preguntas abiertas

- ¿Los valores de 999 y 997 en PM2.5 y PM10 corresponden a errores de sensor o a eventos reales extremos?
- ¿Qué tan estable es la relación entre O_3 , SR y TOUT a lo largo del año, por ejemplo entre temporada seca y de lluvias?
- ¿Conviene modelar cada estación por separado dada la heterogeneidad observada en las correlaciones de O_3 contra PM por estación?

7. Anexos




Figura 1: Boxplots de O₃, PM_{2.5} y PM₁₀ por estación de monitoreo




Figura 4: Distribución de registros válidos por estación de monitoreo




Figura 2: Histogramas con curva de densidad (KDE) de O₃, PM_{2.5} y PM₁₀




Figura 3: Matriz de correlación de Pearson entre O₃, PM_{2.5}, PM₁₀, SR y TOUT




Figura 5: Dispersión PM_{2.5} vs. O₃, coloreado por radiación solar (SR)

8. Declaratoria de uso de IA

Opción B. Se utilizó IA de la siguiente forma.

- **Herramientas.** Google Gemini y ChatGPT (OpenAI).
- **Uso realizado.** Se utilizaron como apoyo para revisar la lógica del código desarrollado con Pandas, contrastar conceptos, mejorar la claridad de la redacción técnica y corregir la estructura y sintaxis del documento en LaTeX.
- **Secciones donde se utilizó.** Anexos, Exploración de Datos, Descripción de Variables, Técnicas Estadísticas Propuestas.
- **Validación realizada por los estudiantes.** Revisamos las sugerencias generadas. Asimismo se interpretaron y se validaron que las descripciones metodológicas coincidieran con los procedimientos ejecutados.
- Comprendemos las decisiones adoptadas y asumimos la responsabilidad por la exactitud, integridad y contenido final del documento.

9. Acceso a la Base de Datos y Código

Repositorio: https://github.com/Eugenioxss/MA2003B_Eq1

Referencias

- [1] Indicadores de la calidad del aire. (2026). *Instituto Nacional de Ecología y Cambio Climático*. <https://sinaica.inecc.gob.mx/scica/>
- [2] Instituto Nacional de Ecología y Cambio Climático. (2026). *Indicadores de la calidad del aire*. [Sistema de Consulta de Indicadores de Calidad del Aire]. <https://sinaica.inecc.gob.mx/>
- [3] International Organization for Standardization. (s. f.). *Calidad del aire*. <https://www.iso.org/es/sectores/medioambiente/calidad-del-aire>
- [4] Islam, N., Toha, T. R., Islam, M. M., & Ahmed, T. (2023). *Spatio-temporal variation of meteorological influence on PM_{2.5} and PM₁₀ over major urban cities of Bangladesh*. [Aerosol and Air Quality Research, 23(1), 220082]. <https://doi.org/10.4209/aaqr.220082>
- [5] Ministerio para la Transición Ecológica y el Reto Demográfico. (s. f.). *Ozono troposférico* [Ministerio Para la Transición Ecológica y el Reto Demográfico]. https://www.miteco.gob.es/es/biodiversidad/temas/inventarios-nacionales/redes-europeas-seguimiento-bosques/red_ozono.html
- [6] Organización Mundial de la Salud. (2021). *Directrices mundiales de la OMS sobre la calidad del aire*. [OMS]. <https://www.who.int/es/news-room/questions-and-answers/item/who-global-air-quality-guidelines>
- [7] Pons, È. (2024, 13 marzo). *El ozono, un contaminante del aire con dos caras*. [ISGLOBAL]. <https://www.isglobal.org/healthisglobal/-/custom-blog-portlet/el-ozono-un-contaminante-del-aire-con-dos-caras>
- [8] Programa de las Naciones Unidas para el Medio Ambiente. (2022). *¿Cómo se mide la calidad del aire?* PNUMA. <https://www.unep.org/es/noticias-y-reportajes/reportajes/como-se-mide-la-calidad-del-aire>
- [9] Ricardo, R. (2025). *Ozono Troposférico: Qué es, Causas e Importancia*. [Estudiando]. <https://estudiando.com/ozono-troposferico-que-es-causas-e-importancia>
- [10] Sanitas. (2026). *Efectos del ozono sobre la salud*. [Sanitas]. <https://www.sanitas.es/biblioteca-de-salud/estilo-vida/efectos-ozono#:~:text=La%20organizaci%C3%B3n%20Mundial%20de%20la%20Salud%20ha%20establecido,el%20asma%2C%20adem%C3%A1s%20de%20favorecer%20las%20infecciones%20respiratorias>
- [11] Sistema Nacional de Información de la Calidad del Aire, SINAICA. (2026, 27 agosto). *Gobierno de México*. <https://sinaica.inecc.gob.mx/>
- [12] Solaz Portolés, J. J. (2001). *El ozono atmosférico, ¿benefactor o malhechor?* *Caderno Catarinense de Ensino de Física*, 18(3), 350–363
- [13] Torres, B. (2023, 23 febrero). *En aumento las contingencias ambientales en CDMX y área metropolitana*. [UNAM Global Revista]. https://unamglobal.unam.mx/global_revista/en-aumento-las-contingencias-ambientales-en-co