

Adecuación y/o Validación del Modelo

Entrega 3

Integrantes:

Irasema Álvarez Treviño - A01286449
Miguel Ángel Hernández Ochoa - A00830949
Eugenio Moreno Vargas - A01723720
Natalia Ixchel Reynoso Ramírez - A01352603
Abraham Vicente González - A01199401

Materia: Aplicación de Métodos Multivariados en Ciencia de Datos (Gpo. 101)

Socio formador: SIMA (Sistema Integral de Monitoreo Ambiental)

Profesores: Blanca Rosa Ruiz Hernández — Raúl Gómez Muñoz

Fecha: 3 de septiembre de 2026

ITESM

1. Objetivo, preguntas de investigación e hipótesis

1.1. Delimitación del objetivo

La Etapa 1 planteó una pregunta amplia sobre la influencia del clima en los contaminantes medidos por el SIMA. En la Etapa 2 el objetivo se acotó a la relación entre el ozono troposférico (O_3) y el material particulado ($PM_{2.5}$, PM_{10}) bajo determinadas condiciones meteorológicas, motivada por la observación del socio formador de que periodos con partículas bajas coinciden con ozono alto. Ambos son contaminantes clave para los que la OMS fija niveles indicativos por su impacto sanitario (Organización Mundial de la Salud, 2021), de modo que anticipar sus episodios tiene valor directo para el socio formador. La retroalimentación de esa entrega señaló que la sección metodológica debía depurarse: conservar solo las técnicas esenciales y vincular cada una, de forma explícita, con la pregunta y las variables que resuelve. En consecuencia, esta entrega (i) elimina las técnicas de reducción de dimensionalidad de propósito general, en particular el ACP, porque no responden a ninguna de las preguntas planteadas (Sec. 3.5), y (ii) fija el objetivo en términos de una estructura temporal contrastable.

Objetivo general. Modelar y validar la dinámica de formación del ozono troposférico —expresado como promedio móvil de 8 horas conforme a la NOM-020-SSA1-2021 (Svarch, 2020)— en el Área Metropolitana de Monterrey (AMM) durante 2020–2025, en función de su dependencia *desfasada* con el material particulado ($PM_{2.5}$, PM_{10}) y del forzamiento meteorológico exógeno (radiación solar, temperatura y viento en componentes cartesianas), evaluando formalmente la adecuación del modelo mediante los supuestos de Gauss–Markov.

1.2. Preguntas de investigación

- P1. ¿Qué familia de distribución describe el comportamiento de $PM_{2.5}$ y PM_{10} y qué técnicas quedan habilitadas o excluidas por esa forma distribucional?
- P2. ¿Existe entre partículas y O_3 una asociación que la correlación simultánea no detecta y, de existir, en qué rezago horario alcanza su máximo?
- P3. ¿Qué proporción de la varianza del O_3 explica un modelo lineal con rezagos y qué signo y magnitud tiene cada forzamiento?
- P4. ¿Es válida la inferencia de ese modelo bajo los supuestos clásicos y, de no serlo, qué conclusiones sobreviven?

1.3. Hipótesis

- **H₀:** La concentración de O_3 responde de manera lineal y *simultánea* a contaminantes y meteorología; los valores rezagados de $PM_{2.5}$ y PM_{10} no aportan información adicional sobre el O_3 presente.
- **H₁:** La respuesta es *desfasada y asimétrica*: la radiación solar y la temperatura anteceden la formación de O_3 , mientras que concentraciones previas de $PM_{2.5}$ la atenúan por bloqueo radiativo y el NO_X reciente la destruye por titulación.

2. Datos y preparación para el modelado

2.1. Del conjunto de la Etapa 2 al conjunto de modelado

La ingesta partió de seis archivos Excel anuales (2020–2025) con 86 pestañas (una por estación y año) que, tras normalizar la columna temporal y concatenarse en un formato columnar único, produjeron 754,603 registros y 20 columnas (15 mediciones más metadatos). Las banderas de error se conservaron deliberadamente en esta fase para poder cuantificarlas después.

La Etapa 2 dejó pendiente un problema de calidad explícito: los valores exactos de 999 y 997 en $PM_{2.5}$ y PM_{10} , incompatibles con los rangos operativos de los sensores y con un IQR de 15.88 y 38.00 respectivamente. Ese pendiente se atendió aquí en dos pasos: coerción numérica que elimina las banderas de texto, y aplicación de un diccionario de *límites operativos año por año* construido con los manuales del fabricante y los reportes del SIMA, que anula los valores físicamente imposibles antes de cualquier cálculo. La limpieza se materializó en 15 archivos independientes —uno por variable— de modo que la falla de un sensor no propague su corrupción al resto del conjunto. La Tabla 1 resume la cobertura resultante.

Variable	Registros válidos	Cobertura
SR	725,814	96.2 %
PM_{10}	719,672	95.4 %
$TOUT$	701,649	93.0 %
O_3	643,436	85.3 %
NO_X	627,434	83.2 %
$PM_{2.5}$	564,250	74.8 %
Matriz de modelado	413,291	71.04 %

Tabla 1: Registros válidos tras la depuración física, sobre el total consolidado de 754,603 observaciones horarias.

El diagnóstico de huecos temporales, realizado con un algoritmo contador de rachas continuas de nulos, justifica la estrategia de integración elegida. La estación Centro (CE) registró una interrupción continua de 1,333 horas (55.5 días) en el sensor de NO_X ; el sensor de $PM_{2.5}$ de la estación NE3 acumuló 94.96 % de nulos en su registro original; y la pérdida por contaminante alcanzó máximos de 69 % para NO_2 en 2020. Imputar sobre huecos de esa magnitud introduciría estructura artificial precisamente en la dimensión temporal que este trabajo pretende estimar. Por ello se evitó la interpolación y se preservó la eliminación por lista mediante un *inner join* estricto sobre las ocho variables predictoras. La optimización algorítmica de las ventanas móviles bajo la tolerancia de completitud de las normas NOM-020 y NOM-172 permitió conservar 536,075 registros completos y alineados temporalmente, equivalentes al 71.04 % del consolidado.

2.2. Ingeniería de características

Sobre esa matriz se aplicaron tres transformaciones con respaldo físico y normativo:

(1) **Vectores ortogonales de viento.** La dirección polar WDR es una variable circular y no admite prome-

dios ni regresión en su escala original. Se descompuso en componentes cartesianas respetando la convención meteorológica (dirección de procedencia):

$$U = -WSR \cdot \sin(\theta), \quad V = -WSR \cdot \cos(\theta) \quad (1)$$

de modo que $U > 0$ indica flujo hacia el este y $V > 0$ flujo hacia el norte.

(2) Algoritmo NowCast (NOM-172-SEMARNAT-2019). Para las partículas se programó la ponderación exponencial oficial, que penaliza las ventanas de alta variabilidad en lugar de promediarlas aritméticamente:

$$w = \max\left(\frac{C_{min}}{C_{max}}, 0.5\right); \quad PM_{12h} = \frac{\sum_{i=0}^{11} w^i C_{11-i}}{\sum_{i=0}^{11} w^i} \quad (2)$$

(3) Ozono a 8 horas (NOM-020-SSA1-2021). Promedio móvil continuo de ocho horas con exigencia de completitud del 75 %, que es la métrica con la que la norma evalúa el cumplimiento y con la que el INECC construye sus indicadores públicos (Instituto Nacional de Ecología y Cambio Climático, 2026; Svarch, 2020). Sobre estas series se generaron los rezagos $C(t - \tau)$ que alimentan el modelo.

2.3. La estación de monitoreo como variable de control

Estacion es la única variable cualitativa del conjunto (15 niveles) y resulta indispensable porque opera como *proxy* de ubicación geográfica y contexto de emisión. Su distribución es marcadamente desigual (Figura 4, Anexo): NE3 y NO3 aportan 0.44 % y 0.74 % de los registros, frente a ocho estaciones que concentran entre 6.9 % y 9.4 % cada una. Además, la correlación O_3 – PM no es homogénea entre sitios, ya que varía de -0.31 en NE3 a $+0.26$ en SUR. Por esa razón el modelo de esta entrega se estima *agrupado* (*pooled*) y la estratificación espacial se declara como pendiente concreto en la Sec. 7, con exclusión explícita de NE3 y NO3 por representatividad insuficiente.

3. Selección y justificación de las técnicas

Cada técnica se retuvo solo si cumple tres criterios: (i) responde a una de las preguntas P1–P4; (ii) es compatible con la escala y la forma distribucional empírica de las variables involucradas; y (iii) cuenta con respaldo en literatura reciente sobre calidad del aire. La Tabla 2 sintetiza la correspondencia técnica–pregunta–variables–sustento.

3.1. Ajuste paramétrico de distribuciones por MLE (P1)

La física de aerosoles implica que las concentraciones tienen soporte estrictamente positivo, se generan por procesos multiplicativos y admiten eventos extremos, de modo que la normalidad no es un supuesto razonable (Seinfeld & Pandis, 2016). Meirelles y Vasconcelos (2025)

verifican empíricamente esta consecuencia y reportan, para series horarias de las Azores en 2024, que $PM_{2.5}$ se ajusta mejor a una *lognormal* y PM_{10} a una *gamma*. Replicar ese contraste en la cuenca de Monterrey no es un ejercicio descriptivo accesorio: es el que decide qué métodos son admisibles. Si la forma es fuertemente asimétrica, la estandarización z y las técnicas construidas sobre la matriz de covarianzas —el ACP entre ellas— dejan de ser lecturas válidas de la estructura de los datos. *Variables:* $PM_{2.5}$, PM_{10} .

3.2. Función de correlación cruzada, CCF (P2)

La CCF evalúa $\rho_{xy}(\tau) = \text{corr}(x_{t-\tau}, y_t)$ para un rango de rezagos τ , y con ello permite *estimar* el desfase en lugar de suponerlo. Es la técnica indicada aquí por una razón documentada: Shao et al. (2022) muestran que el desfase entre $PM_{2.5}$ y O_3 no tiene dirección universal —a escala regional los episodios de O_3 siguen a los de partículas por uno o dos días, mientras que en escalas menores a un día el orden se invierte con desfases de 4 a 12 horas—, de manera que fijar un rezago a priori sesgaría el resultado. El Mghouchi y Udristoiu (2026) emplean este mismo enfoque de análisis desfasado entre ozono superficial, meteorología y otros contaminantes, y advierten que la precedencia temporal debe interpretarse como capacidad predictiva y no como causalidad química. La búsqueda se ejecutó sobre una ventana de ± 48 horas, suficiente para cubrir dos ciclos diurnos completos. *Variables:* $O_{3,8h}$ frente a $PM_{2.5}$, PM_{10} , SR , $TOUT$ y NO_X .

3.3. Modelo de regresión con rezagos distribuidos por MCO (P3)

Un modelo de regresión con rezagos distribuidos estimado por mínimos cuadrados ordinarios cuantifica el efecto conjunto y el signo de cada predictor desfasado sobre el O_3 . Islam et al. (2023) utilizan regresión múltiple con la misma finalidad —medir cuánto de la variación diaria de partículas explican en conjunto las variables meteorológicas— y reportan hasta un 39 %, lo que ofrece un punto de comparación directo para nuestro R^2 . La diferencia metodológica relevante es que aquí el conjunto de rezagos no es arbitrario: proviene de la CCF de la sección anterior, lo que evita el ajuste por prueba y error. *Variables:* respuesta $O_{3,8h}$; predictores $PM_{2.5}(t - 8)$, $PM_{10}(t - 8)$, $SR(t - 17)$, $TOUT(t - 2)$, $NO_X(t - 1)$, U , V .

3.4. Diagnóstico de supuestos de Gauss–Markov (P4)

Con $N \approx 5.4 \times 10^5$ observaciones cualquier contraste alcanza significancia, por lo que la adecuación del modelo no puede juzgarse por los p -valores sino por la estructura de los residuos. Se aplican por tanto el factor de inflación de varianza (VIF) para multicolinealidad, Durbin–Watson para autocorrelación, Breusch–Pagan para heterocedasticidad y Kolmogorov–Smirnov sobre residuos para normalidad. Este diagnóstico es el que determina qué conclusiones del modelo son defendibles y cuáles re-

Técnica	Pregunta que responde	Variables	Sustento académico
Ajuste paramétrico por MLE + KS	P1: ¿qué familia describe las partículas y qué métodos habilita?	$PM_{2.5}$, PM_{10}	Meirelles y Vasconcelos (2025) (log-normal/gamma en series horarias); Seinfeld y Pandis (2016) (fundamento físico)
Correlación cruzada (CCF)	P2: ¿en qué rezago es máxima la asociación partículas-ozono?	$O_{3,8h}$ vs. $PM_{2.5}$, PM_{10} , SR , $TOUT$, NO_X	Shao et al. (2022) (el desfase no es universal); El Mghouchi y Udrisioiu (2026) (análisis desfasado ozono-meteorología)
Modelo de regresión con rezagos distribuidos (MCO)	P3: ¿cuánta varianza se explica y con qué signo actúa cada forzamiento?	Respuesta $O_{3,8h}$; predictores rezagados + U, V	Islam et al. (2023) (efecto conjunto meteorológico, hasta 39 % de la variación)
Supuestos de Gauss-Markov (VIF, DW, BP, KS)	P4: ¿es válida la inferencia y qué conclusiones sobreviven?	Residuos $\hat{\epsilon}_t$ y matriz de predictores	Requisito de consistencia del estimador MCO; El Mghouchi y Udrisioiu (2026) sobre control de autocorrelación

Tabla 2: Correspondencia explícita entre cada técnica conservada, la pregunta que resuelve, las variables sobre las que opera y su respaldo bibliográfico.

quieren un estimador distinto. *Variables:* residuos $\hat{\epsilon}_t$ y matriz de predictores.

3.5. Técnicas descartadas y motivo

- **Análisis de componentes principales (ACP).** Se descarta por dos razones verificables sobre nuestros propios datos y no por preferencia metodológica. Primero, el ACP resuelve un problema de redundancia entre predictores y en este conjunto no existe tal redundancia: todos los predictores presentan un $VIF < 5$ (Tabla 4). Segundo, sus componentes son combinaciones lineales sin interpretación fotoquímica, de modo que no permitirían responder P2 ni P3, que exigen el signo y el rezago de *cada* contaminante por separado.
- **Correlación simultánea de Pearson como criterio único.** Se conserva únicamente como diagnóstico descriptivo. Usada como criterio de decisión llevaría a concluir que no existe relación entre partículas y ozono ($r = 0.008$; Figura 3), justo la conclusión que la CCF refuta.
- **Estandarización z previa y MANOVA.** La primera no corrige la asimetría documentada en P1 ni es requisito de MCO. La segunda supone grupos definidos a priori y una respuesta multivariante de interés, mientras que nuestra pregunta es de dependencia temporal sobre una respuesta única.

4. Resultados

4.1. Caracterización estadística y distribucional

La Tabla 3 resume el perfil de las variables, con detección de atípicos por el método de Tukey. Las tres concentraciones presentan media por encima de la mediana y asimetría positiva, patrón visible en la Figura 2; el caso extremo es $PM_{2.5}$, con un coeficiente de asimetría de 8.57 sobre la matriz depurada. El O_3 es la variable mejor comportada (1.16) y la única cuya cola superior tiene lectura normativa directa: la Figura 1 (Anexo) muestra observaciones horarias por encima de los 90 ppb del límite horario de la NOM-020 en prácticamente todas las estaciones.

Var.	Media	Mediana	D.E.	IQR	Sesgo	Atíp.
O_3	27.22	23.00	19.25	24.00	1.16	2.75 %
$PM_{2.5}$	20.40	17.00	15.32	15.88	8.57	3.70 %
PM_{10}	60.92	52.00	40.80	38.00	4.89	4.76 %
SR	0.15	0.01	0.22	0.25	–	5.23 %
$TOUT$	23.59	24.22	7.00	9.27	–	0.88 %

Tabla 3: Medidas de tendencia central, dispersión y proporción de valores atípicos (criterio IQR). Unidades: O_3 en ppb; $PM_{2.5}$ y PM_{10} en $\mu\text{g}/\text{m}^3$; $TOUT$ en $^\circ\text{C}$. Los coeficientes de asimetría corresponden a la matriz depurada de modelado ($N = 536,075$).

El ajuste por máxima verosimilitud con el parámetro de posición fijado en cero ($\text{loc} = 0$) confirma la hipótesis distribucional de Meirelles y Vasconcelos (2025) en la cuenca de Monterrey: $PM_{2.5}$ sigue una **lognormal** ($\mu=3.43$ y $\sigma=3.69$) PM_{10} una **gamma** ($\alpha = 2.18$ y $\theta = 4.27$). Es necesario precisar la lectura de los contrastes: con N del orden de 5×10^5 , la prueba de Kolmogorov-Smirnov tiene potencia suficiente para rechazar cualquier familia cerrada ante desviaciones mínimas, de modo que los p -valores obtenidos para la lognormal y para la gamma no deben leerse como refutación del ajuste sino como evidencia de que ninguna familia paramétrica reproduce exactamente la cola empírica. El criterio útil es comparativo, y bajo ese criterio la gamma describe a PM_{10} con mayor fidelidad que la lognormal a $PM_{2.5}$, coherente con el mayor peso de eventos extremos en la fracción fina.

4.2. Dependencia simultánea frente a dependencia desfasada

La Figura 3 muestra el resultado que motiva toda la etapa: en el instante t , el O_3 correlaciona de forma moderada con radiación solar ($r = 0.530$) y temperatura ($r = 0.488$), $PM_{2.5}$ y PM_{10} correlacionan fuertemente entre sí ($r = 0.606$), pero la asociación entre ozono y partículas es prácticamente nula ($r = 0.008$ y $r = 0.014$). El mismo cálculo se replicó con el coeficiente de Spearman y de forma desglosada por estación, para descartar que la nulidad proviniera de una relación monótona no lineal o de un efecto de agregación espacial. La dispersión de la Figura 3 (derecha) confirma visualmente la ausencia de tendencia lineal simultánea y, al mismo tiempo, que los valores altos de O_3 se concentran en condicio-

nes de radiación elevada con independencia del nivel de partículas.

La CCF revela que esa nulidad es un artefacto del análisis simultáneo. Al recorrer los rezagos aparecen tres estructuras:

- **Bloqueo radiativo (Lag 8).** La correlación negativa máxima entre partículas y ozono ocurre cuando $PM_{2.5}$ y PM_{10} anteceden al O_3 por ocho horas.
- **Periodicidad radiativa (Lag 17).** La asociación máxima de la radiación solar con el ozono aparece con 17 horas de antelación y signo negativo, reflejando la inversión entre fases del ciclo diurno.
- **Titulación reciente (Lag 1–2).** NO_X y $TOUT$ alcanzan su máximo en rezagos cortos, de una y dos horas respectivamente.

4.3. Parámetros del modelo de rezagos distribuidos

Con ese conjunto de rezagos se estimó

$$\begin{aligned} O_{3,8h}(t) = & \beta_0 + \beta_1 PM_{2.5}(t-8) + \beta_2 PM_{10}(t-8) \\ & + \beta_3 SR(t-17) + \beta_4 TOUT(t-2) \\ & + \beta_5 NO_X(t-1) + \beta_6 U + \beta_7 V + \epsilon_t \end{aligned} \quad (3)$$

El modelo explica el 35.91 % de la varianza del ozono ($R^2 = 0.3591$; $R^2_{adj} = 0.3591$) con un RMSE de 12.1390 ppb. La Tabla 4 presenta los coeficientes estimados.

Predictor	β
Constante	7.1924
$TOUT(t-2)$	0.8534
V (comp. norte)	0.2237
$PM_{10}(t-8)$	0.0570
$PM_{2.5}(t-8)$	-0.0116
$NO_X(t-1)$	-0.0856
U (comp. este)	-0.1843
$SR(t-17)$	-14.0170

Nota. La multicolinealidad fue evaluada mediante el cálculo de la diagonal de la matriz inversa de correlación; todos los predictores arrojaron un $VIF < 5$.

Tabla 4: Coeficientes del modelo de regresión con rezagos distribuidos. $R^2 = 0.3591$, RMSE = 12.1390 ppb, $N = 536,075$.

5. Validación de supuestos y adecuación del modelo

Multicolinealidad. Para optimizar el cálculo del VIF, en lugar de estimar regresiones auxiliares sobre los 536,075 registros, resulta computacionalmente más eficiente extraer la diagonal de la inversa de la matriz de correlaciones R^{-1} , reduciendo el costo algorítmico de $O(n \cdot p^2)$ a $O(p^3)$. Todos los predictores arrojaron un $VIF < 5$ (Tabla 4), por lo que no se detectó multicolinealidad que justifique una reducción de dimensionalidad.

Autocorrelación. Durbin–Watson = 0.0756. El estadístico se comparará con el valor de referencia 2; un resultado muy inferior indicaría autocorrelación positiva en los residuos.

Homocedasticidad. Breusch–Pagan con $p < 0.001$ rechaza varianza constante, comportamiento esperable

en un proceso fotoquímico cuya variabilidad crece con el nivel de radiación. *No se cumple.*

Normalidad de residuos. Kolmogorov–Smirnov $D = 0.0567$, $p < 0.001$: residuos con colas pesadas. *No se cumple*, con la salvedad de potencia muestral ya señalada.

Consecuencia para la interpretación. Bajo exogeneidad, los estimadores MCO siguen siendo insesgados y consistentes, de modo que los *signos y órdenes de magnitud* de la Tabla 4 son interpretables. Lo que pierde validez es la inferencia: los errores estándar están subestimados y, por tanto, en esta entrega no se formula ninguna afirmación de significancia estadística. Esta es la razón —y no una preferencia de modelo— por la que el plan de trabajo migra hacia estimadores robustos y especificaciones dinámicas.

6. Discusión

Respuesta a la pregunta del socio formador. La observación de SIMA —partículas bajas coincidiendo con ozono alto— es real pero *no es simultánea*. La correlación instantánea es nula ($r = 0.008$) mientras que el coeficiente de $PM_{2.5}$ rezagado ocho horas es negativo ($\beta = -0.0116$). La interpretación consistente con la fotoquímica es la de un bloqueo radiativo: el aerosol fino presente durante la mañana atenúa la radiación disponible para la fotólisis y limita la producción de ozono de la tarde (Seinfeld & Pandis, 2016; Solaz Portolés, 2001). Se rechaza así H_0 en favor de H_1 .

Comparación con la literatura. El 35.91 % de varianza explicada es del mismo orden que el 39 % de variación diaria de partículas atribuible a meteorología reportado por Islam et al. (2023), lo que sugiere que un modelo lineal con forzamiento meteorológico agota una fracción similar de la variabilidad en ambos contextos y que el residuo corresponde a procesos no lineales y a emisiones no observadas. El desfase de ocho horas encontrado aquí es coherente con la escala subdiaria de 4 a 12 horas documentada por Shao et al. (2022), quienes además advierten que la dirección del desfase depende de la escala y de la circulación, lo que respalda haberlo estimado en lugar de suponerlo.

Titulación y viento. El signo negativo de $NO_X(t-1)$ ($\beta = -0.0856$) reproduce el mecanismo de titulación nocturna por óxido nítrico reciente descrito en la literatura fotoquímica (Ricardo, 2025; Solaz Portolés, 2001). En cuanto al viento, la combinación $\beta_V > 0$ y $\beta_U < 0$ implica, por construcción de las componentes, que el ozono aumenta bajo flujos con dirección hacia el norte y hacia el oeste, es decir, con vientos procedentes del cuadrante sureste; su magnitud, sin embargo, es un orden menor que la del forzamiento térmico.

Periodicidad radiativa. El término $SR(t-17)$ presenta un coeficiente negativo ($\beta = -14.0170$) y no debe interpretarse como un retardo causal de la fotoquímica. El rezago capta la periodicidad diurna y la inversión del ciclo: la alta radiación de la tarde anterior está negativamente correlacionada con la concentración base del ozono a la mañana siguiente, debido al cese de la fotólisis y a la titulación nocturna continua.

Limitaciones que condicionan la lectura. Dos pun-

tos exigen cautela. Primero, $PM_{10}(t - 8)$ presenta signo positivo, opuesto al de $PM_{2.5}$; una explicación plausible —a contrastar— es que la fracción gruesa covaría con condiciones secas, ventosas y de alta radiación que favorecen tanto la resuspensión como la formación de ozono, de modo que no actuaría como bloqueador sino como indicador de esas condiciones. Segundo, el modelo es agrupado y la heterogeneidad entre estaciones documentada en la Etapa 2 (correlación O_3 – PM de -0.31 a $+0.26$) advierte que los coeficientes son promedios espaciales.

7. Conclusiones, pendientes y plan de trabajo

Logros. Se cerró el pendiente de calidad de la Etapa 2 (códigos 999 y 997) y se construyó una matriz de 536,075 observaciones completas con ocho predictores alineados temporalmente. Se caracterizó la forma distribucional de las partículas, se estimó empíricamente la estructura de rezagos que la correlación simultánea ocultaba, y se ajustó y *auditó* un modelo de regresión con rezagos distribuidos, delimitando con precisión qué parte de sus resultados es defendible. El rezago de radiación de $\tau = 17$ y su signo negativo se interpretaron como manifestación de la periodicidad diurna y de la inversión entre la tarde anterior y la mañana siguiente.

Pendientes con acción concreta. Cada punto indica método, variables y criterio de cierre:

- Corregir la inferencia.** Reestimar el mismo modelo de regresión con rezagos distribuidos con errores estándar HAC (Newey–West, ventana de 24 rezagos). *Cierre:* disponer de intervalos de confianza reportables para los siete coeficientes.
- Sustituir el estimador estático.** Implementar una arquitectura LSTM–NARX acelerada por hardware mediante PyTorch/CUDA, capaz de representar la asimetría y la heterocedasticidad comprobadas sin imponer linealidad ni varianza constante. *Cierre:* RMSE de prueba inferior a 12.1390 ppb.
- Estratificar espacialmente.** Reestimar por subcuenca contrastando el noreste industrial (NE, NE2) contra SUR y SO, excluyendo NE3 y NO3 por representatividad menor al 1 %. *Cierre:* tabla comparativa del coeficiente de NO_X y del rezago óptimo por subcuenca, que responde a la pregunta de si el bloqueo radiativo es un fenómeno de cuenca o local.
- Validar fuera de muestra.** Partición temporal 2020–2024 para entrenamiento y 2025 para prueba. *Cierre:* RMSE de prueba reportado junto al de entrenamiento.
- Traducir a producto para SIMA.** Contabilizar excedencias del promedio móvil de 8 horas frente al límite de 0.051 ppm de la NOM-020 por estación y temporada (Svarch, 2020). *Cierre:* tabla de excedencias por estación entregable al socio formador.

Preguntas abiertas. ¿El signo opuesto de PM_{10} frente a $PM_{2.5}$ responde a la resuspensión por viento o a una diferencia real de propiedades ópticas? ¿Cambia el rezago óptimo entre temporada seca y de lluvias, como sugiere la dependencia estacional reportada por Islam et al. (2023)?

Acceso al repositorio y reproducibilidad

Código, notebooks y base de datos limpia disponibles en: https://github.com/Eugenioxss/MA2003B_Eq1. La Tabla 5 mapea cada fase del análisis con el archivo que la ejecuta y su salida, de modo que todos los resultados reportados sean reproducibles en orden.

Fase	Archivo	Salida
1. Ingesta	1_join_raw	sima_raw.parquet
2. Diagnóstico	1.5_xray_lostData	Reporte de rachas de nulos
2. Limpieza	2_clean_split	15 *_clean.parquet
3. Features	3_features	dataset_ozono_predictivo.parquet
4. EDA y CCF	etapa2_analisis, 4_analisis_visual	Figuras 1–4, ajustes MLE, rezagos
5. Modelo	ARX_supuestations_VIFmatrixInversion (nombre histórico)	Coefficientes y supuestos

Tabla 5: Arquitectura del *pipeline* de datos y trazabilidad de cada resultado reportado.

Anexos

Distribución de contaminantes por estación de monitoreo




Figura 1: Distribución de O_3 , $PM_{2.5}$ y PM_{10} por estación de monitoreo. Se observan valores horarios de ozono por encima de los 90 ppb del límite horario de la NOM-020 en prácticamente todas las estaciones, así como la heterogeneidad espacial que motiva la estratificación pendiente.

Distribución de contaminantes — Histograma + KDE




Figura 2: Histogramas con estimación de densidad (KDE). En los tres contaminantes la media supera a la mediana, señal de asimetría positiva. Los coeficientes mostrados corresponden a la integración de la Etapa 2 ($N = 456,519$); sobre la matriz depurada de modelado ($N = 536,075$) los valores son 1.16, 8.57 y 4.89 respectivamente.




Figura 3: Izquierda: matriz de correlación de Pearson simultánea; la asociación O_3 – $PM_{2.5}$ es nula ($r = 0.008$), resultado que la CCF corrige al introducir rezagos. Derecha: dispersión $PM_{2.5}$ vs. O_3 coloreada por radiación solar; los máximos de ozono se alinean con radiación alta y no con un nivel particular de partículas.




Figura 4: Registros válidos por estación de monitoreo. NE3 (0.4 %) y NO3 (0.7 %) quedan excluidas del análisis estratificado por representatividad insuficiente.

Referencias bibliográficas

- El Mghouchi, Y., & Udristioiu, M. T. (2026). A causal analysis of ground-level ozone, meteorological factors, and other air pollutants: An in-depth AI-based study applied to the climate of Craiova City, Romania. *The European Physical Journal Plus*, 141, 277. <https://doi.org/10.1140/epjp/s13360-026-07495-x>
- Instituto Nacional de Ecología y Cambio Climático. (2026). *Indicadores de la calidad del aire: Sistema de Consulta de Indicadores de Calidad del Aire (SCICA)*. <https://sinaica.inecc.gob.mx/>
- Islam, N., Toha, T. R., Islam, M. M., & Ahmed, T. (2023). Spatio-temporal variation of meteorological influence on PM_{2.5} and PM₁₀ over major urban cities of Bangladesh. *Aerosol and Air Quality Research*, 23(1), 220082. <https://doi.org/10.4209/aaqr.220082>
- Meirelles, M. G., & Vasconcelos, H. C. (2025). Physical-Statistical Characterization of PM₁₀ and PM_{2.5} Concentrations and Atmospheric Transport Events in the Azores During 2024. *Earth*, 6(2), 54. <https://doi.org/10.3390/earth6020054>
- Organización Mundial de la Salud. (2021). *Directrices mundiales de la OMS sobre la calidad del aire*. <https://www.who.int/es/news-room/questions-and-answers/item/who-global-air-quality-guidelines>
- Ricardo, R. (2025). *Ozono Troposférico: Qué es, Causas e Importancia*. Estudiando. <https://estudyando.com/ozono-troposferico-que-es-causas-e-importancia/>
- Seinfeld, J. H., & Pandis, S. N. (2016). *Atmospheric Chemistry and Physics: From Air Pollution to Climate Change* (3.^a ed.). John Wiley & Sons.
- Shao, M., et al. (2022). Co-occurrence of surface O₃, PM_{2.5} pollution, and tropical cyclones in China. *Journal of Geophysical Research: Atmospheres*, 127, e2021JD036310. <https://doi.org/10.1029/2021JD036310>
- Solaz Portolés, J. J. (2001). El ozono atmosférico, ¿benefactor o malhechor? *Caderno Catarinense de Ensino de Física*, 18(3), 350-363.
- Svarch, A. (2020). *NORMA Oficial Mexicana NOM-020-SSA1-2021, Salud ambiental*. Diario Oficial de la Federación. https://dof.gob.mx/nota_detalle_popup.php?codigo=5633956

Declaratoria de uso de IA

Opción B. Se utilizó IA

- **Herramientas.** Google Gemini y Claude
- **Uso realizado.** Apoyo en la refactorización del cálculo matricial del VIF, en la estructuración del análisis de correlación cruzada y síntesis del reporte para la retroalimentación de la entrega anterior
- **Secciones donde se utilizó.** Justificación metodológica de técnicas, validación de supuestos y anexos
- **Validación realizada por los estudiantes.** Se ejecutó todos los cálculos reportados sobre la base propia, se verificó que cada cifra del documento corresponda a la salida del código del repositorio y que cada referencia citada exista y sostenga la afirmación asociada
- **Confirmación de que se revisó, verificó y que se asume la responsabilidad del contenido final entregado.** Confirmamos que revisamos y verificamos el contenido, comprendemos toda la información entregada y asumimos la responsabilidad del contenido final del trabajo entregado.