



Conociendo el Negocio

Entrega 1

Integrantes:

Irasema Álvarez Treviño - A01286449

Miguel Angel Hernández Ochoa - A00830949

Eugenio Moreno Vargas - A01723720

Natalia Ixchel Reynoso Ramírez - A01352603

Abraham Vicente González - A01199401

Materia: Aplicación de Métodos Multivariados en Ciencia de
Datos (Gpo. 101)

Socio formador: SIMA (Sistema Integral de Monitoreo
Ambiental)

Profesores: Blanca Rosa Ruiz Hernández — Raúl Gómez Muñoz

Fecha: 20 de agosto del 2026

ITESM

Índice

1. Conociendo el Negocio	2
1.1. Introducción	2
1.2. Fuentes Bibliográficas y de Datos	5
2. Comprensión y Preparación de los Datos	6
2.1. Comprensión de los Datos	6
2.1.1. Dimensión del Dataset	6
2.1.2. Verificación de la Calidad de los Datos	7
2.2. Preparación de los Datos	7
2.2.1. Selección del Conjunto de Datos	7
2.2.2. Identificación de las Columnas Objetivo	7
2.2.3. Limpieza de Datos	7
2.3. Transformación de Datos	8
2.3.1. Discretización (binning)	8
2.3.2. Escalamiento y Normalización	8
2.3.3. Construcción de Atributos Derivados	8
2.4. Informe de Preparación de los Datos	8
2.4.1. Tamaño del Dataset y Porcentaje de Datos Perdidos	8
2.4.2. Variables Relevantes	9
2.4.3. Resumen del Trabajo de Preparación de Datos	9
2.4.4. Acceso a la Base de Datos Limpia	10
2.4.5. Declaratoria de Uso de IA	10
2.5. Fuentes Bibliográficas y de Datos	11

1. Conociendo el Negocio

1.1. Introducción

La contaminación atmosférica constituye uno de los principales retos ambientales y de salud pública a nivel mundial. De acuerdo con el Programa de las Naciones Unidas para el Medio Ambiente (PNUMA), con base en datos de la Organización Mundial de la Salud (OMS), el 99 % de la población mundial respira aire considerado insalubre y la contaminación atmosférica se relaciona con aproximadamente siete millones de muertes prematuras cada año. Entre los contaminantes de mayor relevancia se encuentran las partículas suspendidas $PM_{2.5}$ y PM_{10} , el ozono troposférico (O_3), el dióxido de nitrógeno (NO_2), el dióxido de azufre (SO_2) y el monóxido de carbono (CO). Particularmente, las $PM_{2.5}$ representan un riesgo importante debido a su reducido tamaño, que les permite penetrar profundamente en el organismo y se asocia con enfermedades cardiovasculares, respiratorias y cáncer (Programa de las Naciones Unidas para el Medio Ambiente [PNUMA], 2022).

Ante esta problemática, el monitoreo sistemático de la calidad del aire resulta fundamental para conocer las condiciones atmosféricas de una región, identificar tendencias y proporcionar información que permita desarrollar estrategias de prevención y control. Organismos internacionales como la ISO (*International Organization for Standardization*) establecen métodos y referencias para realizar mediciones de contaminantes atmosféricos, mientras que las Directrices Mundiales de la OMS sobre la Calidad del Aire establecen niveles indicativos y metas intermedias para contaminantes clave con base en evidencia científica sobre sus efectos en la salud. De esta manera, la medición no solo permite cuantificar la contaminación, sino también evaluar el grado de exposición de la población y sustentar la toma de decisiones y el desarrollo de políticas ambientales (Organización Mundial de la Salud [OMS], 2021).

La calidad del aire es resultado de un fenómeno complejo en el que interactúan tanto las fuentes de emisión como las condiciones atmosféricas. Los contaminantes pueden proceder de fuentes antropogénicas, como el uso de combustibles fósiles, o de fenómenos naturales, como incendios forestales y tormentas de polvo (PNUMA, 2022). Para su vigilancia se utilizan estaciones de monitoreo, sensores e incluso observaciones satelitales, cuyos registros pueden integrarse en bases de datos para analizar las concentraciones de contaminantes y construir indicadores de calidad del aire. Sin embargo, las mediciones pueden verse afectadas por problemas de disponibilidad y validación de datos, mantenimiento y calibración de los equipos, condiciones ambientales y la ubicación de las estaciones, por lo que garantizar información continua, representativa y confiable constituye un desafío adicional para su análisis.

Además de las fuentes de emisión, las condiciones meteorológicas pueden modificar significativamente las concentraciones observadas de contaminantes. Según Rahman et al. (2022), variables como la temperatura, precipitación, humedad, viento, radiación solar y hora del día han sido estudiadas mediante herramientas como análisis de correlación, comparaciones temporales y regionales y modelos estadísticos. Un estudio realizado con datos de seis ciudades de Bangladesh entre 2013 y 2018, por ejemplo, analizó las concentraciones de $PM_{2.5}$ y PM_{10} junto con distintas variables meteorológicas mediante correlaciones y regresión no lineal

múltiple. Sus resultados indicaron que las condiciones meteorológicas podrían explicar hasta el 39 % de la variación diaria de las partículas durante episodios de alta contaminación y mostraron que factores como la precipitación y la temperatura presentaban efectos diferentes dependiendo de la región y la temporada.

En el contexto de Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA) es la red gubernamental encargada de monitorear y evaluar la calidad del aire mediante la medición continua de contaminantes atmosféricos y variables meteorológicas. La información generada por sus estaciones permite estudiar el comportamiento de la contaminación en la Zona Metropolitana de Monterrey y constituye una fuente de datos de gran valor para identificar patrones y relaciones entre múltiples variables.

En este contexto, y mediante la colaboración con SIMA como socio formador, el proyecto busca abordar el problema desde la ingeniería en ciencia de datos y matemáticas, con el propósito de analizar cómo los niveles de contaminación del aire varían entre distintas regiones en función de condiciones climáticas como la lluvia y la temperatura, así como de la hora del día. A través del análisis multivariado de los datos proporcionados por SIMA, se busca identificar patrones, relaciones y factores que permitan comprender con mayor profundidad la dinámica de la calidad del aire en Monterrey y generar información útil para su interpretación y posterior toma de decisiones.

A partir de la problemática, planteamos tres preguntas de investigación que permiten orientar el desarrollo del proyecto:

1. ¿En qué medida las variables meteorológicas explican la variación temporal de las concentraciones de los principales contaminantes atmosféricos registrados por SIMA?
2. ¿Qué relación existe entre la disminución de las concentraciones de partículas $PM_{2.5}$ y PM_{10} y el aumento de las concentraciones de ozono (O_3), y bajo qué condiciones meteorológicas se presenta con mayor frecuencia este comportamiento?
3. ¿Qué patrones o indicadores pueden construirse a partir de la combinación de contaminantes, variables meteorológicas, ubicación y concentración poblacional para identificar zonas y periodos de mayor exposición potencial de la población a una mala calidad del aire?

Con base en estas preguntas, planteamos el siguiente objetivo:

Analizar la variación de la concentración de partículas contaminantes entre distintas regiones en función de las condiciones climáticas y de la hora del día.

La primera pregunta se relaciona con el análisis de cómo la lluvia, la temperatura y otras variables meteorológicas influyen en los cambios de las concentraciones a lo largo del tiempo. La segunda pregunta se relaciona con el estudio conjunto de diferentes contaminantes y las condiciones climáticas bajo las cuales cambian sus concentraciones. Finalmente, la tercera pregunta corresponde a la comparación entre regiones.

En conjunto, las tres preguntas pueden responderse mediante el objetivo planteado y permiten comprender la variación de la calidad del aire desde una perspectiva temporal, meteorológica y regional.

1.2. Fuentes Bibliográficas y de Datos

Referencias

- [1] [International Organization for Standardization. (s. f.). Calidad del aire. ISO. <https://www.iso.org/es/sectores/medioambiente/calidad-del-aire>]
- [2] [Rahman et al. (2022). Estudio sobre la relación entre las condiciones meteorológicas y las concentraciones de PM2.5 y PM10 en seis ciudades de Bangladesh. Aerosol and Air Quality Research. <https://aaqr.org/articles/aaqr-22-02-ssea-0082>]
- [3] [Organización Mundial de la Salud. (2021). Directrices mundiales de la OMS sobre la calidad del aire. <https://www.who.int/es/news-room/questions-and-answers/item/who-global-air-quality-guidelinesReferencia>]
- [4] [Programa de las Naciones Unidas para el Medio Ambiente. (2022). ¿Cómo se mide la calidad del aire? <https://www.unep.org/es/noticias-y-reportajes/reportajes/como-se-mide-la-calidad-del-aire>]

2. Comprensión y Preparación de los Datos

2.1. Comprensión de los Datos

2.1.1. Dimensión del Dataset

El conjunto de datos crudo, obtenido tras la unión de los archivos (2020-2025), consta de 754,603 registros y 17 columnas. La estructura base presenta una resolución temporal de una hora.

Variable	Descripción	Tipo	Valores posibles	% Nulos
Date	Marca temporal de la medición (fecha y hora)	Temporal	2020-01-01 a 2025-12-31	0.0 %
Estacion	Clave de la estación de monitoreo del SIMA	Categorico	CE, NE, SE, SO, SUR, etc. (15 estaciones)	0.0 %
CO	Concentración de monóxido de carbono	Numérico	0–50 ppm (variable por año)	~12.5 %
NO	Concentración de monóxido de nitrógeno	Numérico	0–500 ppb (variable por año)	~15.2 %
NO2	Concentración de dióxido de nitrógeno	Numérico	0–200 ppb (variable por año)	~17.8 %
NOX	Óxidos de nitrógeno totales (NO + NO ₂)	Numérico	0–500 ppb (variable por año)	~16.4 %
O3	Concentración de ozono troposférico	Numérico	0–185 ppb (variable por año)	~14.1 %
PM10	Partículas suspendidas menores a 10 μm	Numérico	0–999 $\mu\text{g}/\text{m}^3$ (variable por año)	~4.3 %
PM2.5	Partículas suspendidas menores a 2,5 μm	Numérico	0–999 $\mu\text{g}/\text{m}^3$ (variable por año)	~21.5 %
PRS	Presión barométrica	Numérico	680 – 750 mmHg	~3.8 %
RAINF	Precipitación pluvial acumulada por hora	Numérico	0 – 80 mm	~3.5 %
RH	Humedad relativa del aire	Numérico	0 – 100 %	~6.2 %
SO2	Concentración de dióxido de azufre	Numérico	0 – 405 ppb (variable por año)	~14.9 %
SR	Radiación solar global	Numérico	0 – 1.4 kW/m ²	~2.1 %
TOUT	Temperatura exterior del aire	Numérico	–6,5 – 45,5 °C	~3.4 %
WSR	Velocidad del viento	Numérico	0 – 75 km/h	~4.1 %
WDR	Dirección del viento	Numérico	0 – 360°	~5.2 %

Cuadro 1: Descripción completa de las variables del dataset consolidado SIMA (2020-2025).

2.1.2. Verificación de la Calidad de los Datos

Mediante un análisis diagnóstico exploratorio (Rayos X”), se identificaron tres problemas críticos en la calidad original de los datos:

1. Banderas alfanuméricas: Presencia de caracteres de invalidación (ej. 'p' por falla eléctrica, 'c' por calibración) incrustados en columnas numéricas.
2. Vacíos estructurales prolongados: Se detectaron rachas de desconexión severas, por ejemplo, la estación Centro (CE) registró hasta 1,333 horas consecutivas (aprox. 55 días) sin lectura de NO_X .
3. Degradación temporal: El año 2020 presentó niveles de pérdida de datos superiores al 60 % en gases precursores. Sin embargo, la medición de $PM_{2.5}$ mostró un deterioro en años recientes, con más del 30 % de datos perdidos en 2024 y 2025.

2.2. Preparación de los Datos

2.2.1. Selección del Conjunto de Datos

Se incluyó el histórico completo de las 15 estaciones de monitoreo del SIMA. Sin embargo, para mitigar el sesgo introducido por los vacíos estructurales prolongados, la arquitectura de datos se separó temporalmente en 15 tablas independientes (una por variable) para evitar que la falla de un sensor obligara a descartar las lecturas válidas de los demás instrumentos en esa misma hora.

2.2.2. Identificación de las Columnas Objetivo

Para el análisis de dinámica fotoquímica, se definió el Ozono (O_3) como la variable objetivo principal, utilizando como variables predictoras los óxidos de nitrógeno (NO_X) y las condiciones meteorológicas clave/relevantes (Radiación Solar, Temperatura, Velocidad y Dirección del viento).

2.2.3. Limpieza de Datos

- **Eliminación de duplicados:** Se manejó implícitamente al estandarizar la columna temporal (Date) y alinear los registros bajo una estructura estricta de joins horarios.
- **Corrección de valores espurios o erróneos:** Se eliminaron las banderas de error forzando la conversión numérica. Posteriormente, se aplicó un filtrado de Rangos Dinámicos.^{año} por año dictaminado por los manuales operativos del SIMA.
- **Manejo de valores faltantes:** Debido a las rachas de meses de desconexión, se optó por tomar un camino estricto de eliminación de nulos (dropna) sobre las tablas aisladas por variable. Se descartó la imputación sintética (interpolación lineal o arrastre) para no fabricar fenómenos meteorológicos ficticios que corrompieran el entrenamiento del modelo. Ésto estará sujeto a evaluación durante las siguientes etapas, debido a que tenemos la facilidad de volver a armar una base de datos unida en caso de ser viable.

- **Manejo de valores atípicos (outliers):** Se tomó la decisión crítica de no eliminar los valores atípicos mediante métodos estadísticos tradicionales. Dado que fenómenos meteorológicos extremos como tolvaneras o incendios pueden generar picos reales y legítimos de contaminación, un filtro estadístico habría borrado eventos climáticos importantes. En su lugar, el filtrado de valores atípicos se realizó estrictamente con base en los "Límites de Operación instrumentales dictaminados por el SIMA para cada año. Por ejemplo, lecturas de PM_{10} superiores a $800 \mu g/m^3$ en 2020 fueron eliminadas no por ser estadísticamente raras, sino porque excedían el rango de operación del sensor en ese periodo.

2.3. Transformación de Datos

2.3.1. Discretización (binning)

No se consideró necesaria en esta etapa inicial, priorizando la variable continua para los modelos de regresión, aunque podría implementarse posteriormente para clasificar el Índice de Aire y Salud (bueno, malo, muy malo).

2.3.2. Escalamiento y Normalización

No se realizó, debido a que se mantiene sin definir el tipo de modelo(s), y técnicas de análisis y ciencia de datos a usar durante las siguientes etapas del proyecto.

2.3.3. Construcción de Atributos Derivados

Para habilitar el modelado predictivo, se diseñaron variables derivadas bajo fundamentos físicos:

- **Vectores de Viento (Transporte):** Para resolver la circularidad matemática de los grados (WDR), se descompuso la magnitud (WSR) en vectores cartesianos utilizando trigonometría:

$$U = -WSR \cdot \sin\left(WDR \cdot \frac{\pi}{180}\right)$$

$$V = -WSR \cdot \cos\left(WDR \cdot \frac{\pi}{180}\right)$$

- **Rezagos Temporales (Time-Lags):** Dado que la formación del O_3 requiere acumulación de precursores y exposición a radiación, se generaron atributos históricos para cada registro. Se calcularon retardos espaciales por estación de 1, 2, 3 y 4 horas para NO_X y SR ; y retardos de 2 y 4 horas para $TOUT$, dotando al modelo de "memoria" secuencial.

2.4. Informe de Preparación de los Datos

2.4.1. Tamaño del Dataset y Porcentaje de Datos Perdidos

El dataset unificado en crudo contiene 17 variables (15 de medición ambiental más la fecha y la estación) y está compuesto por 754,603 registros horarios. El porcentaje de datos perdidos

varía de manera independiente por sensor y por año. Las variables meteorológicas (como Temperatura y Viento) presentan la mayor estabilidad (aproximadamente 4-7 % de pérdida), mientras que contaminantes como el $PM_{2.5}$ alcanzan hasta un 30 % de datos perdidos en los últimos años, y gases precursores como el NO_X superaron el 60 % de pérdida durante el 2020.

2.4.2. Variables Relevantes

Para cumplir con el objetivo del proyecto (predecir y entender el comportamiento de la contaminación y su relación con el clima), se seleccionaron las siguientes variables clave:

- **Variables Objetivo:** Ozono (O_3) y Partículas Suspendidas (PM_{10} y $PM_{2.5}$), al ser los principales indicadores de mala calidad de aire.
- **Variables Meteorológicas:** Temperatura ($TOUT$), Radiación Solar (SR) y Viento (WSR , WDR). Son fundamentales porque la radiación y temperatura catalizan la formación de Ozono, mientras que el viento dispersa las partículas.
- **Variables Precursoras:** Óxidos de Nitrógeno (NO_X) y Monóxido de Carbono (CO), indispensables para analizar la dinámica fotoquímica de la atmósfera.

2.4.3. Resumen del Trabajo de Preparación de Datos

- **Unión o separación de bases:** Se extrajeron y concatenaron las hojas de los archivos de Excel anuales correspondientes al periodo 2020–2025 para construir el archivo histórico `sima_raw.parquet`. Posteriormente, con el fin de manejar los valores nulos de manera independiente, la base se dividió en 15 archivos, uno por cada variable de medición.
- **Limpieza de los datos:** Se convirtieron las columnas de medición a formato numérico mediante la opción `coerce`, por lo que las banderas alfanuméricas de invalidación fueron reemplazadas por valores nulos. Después, se aplicaron rangos operativos definidos con base en los reportes anuales del SIMA para identificar y descartar lecturas fuera de los límites válidos de medición.
- **Imputación:** No se aplicaron técnicas de imputación sintética; por tanto, el porcentaje de valores imputados fue de 0 %.
- **Porcentaje de datos faltantes, atípicos y duplicados:** No se conservaron registros duplicados para una misma combinación de fecha, hora y estación. Los porcentajes de valores faltantes y lecturas fuera de los rangos operativos varían según la estación, la variable y el año. Las lecturas inválidas se convirtieron en valores nulos antes de la separación de las bases.
- **Porcentaje de datos eliminados y motivo:** En cada archivo se eliminaron de manera independiente, mediante `dropna`, las filas cuyo valor para la variable correspondiente era `NaN`. Estos valores provenían de fallas o periodos de desconexión de los sensores, banderas de invalidación o lecturas fuera de los rangos operativos. En consecuencia, cada archivo `.parquet` resultante contiene únicamente observaciones disponibles que superaron los criterios de validación establecidos.

2.4.4. Acceso a la Base de Datos Limpia

[https://github.com/Eugenioxss/MA2003B_Eq1]

2.4.5. Declaratoria de Uso de IA

Opción B. Se utilizó IA de la siguiente forma:

- **Herramientas:** Google Gemini y ChatGPT (OpenAI).
- **Uso realizado:** Se utilizaron como apoyo para revisar la lógica del código desarrollado con Pandas, contrastar conceptos estadísticos y ambientales relacionados con el tratamiento de valores atípicos en datos de calidad del aire, mejorar la claridad de la redacción técnica y corregir la estructura y sintaxis del documento en LaTeX.
- **Secciones donde se utilizó:** Comprensión y preparación de los datos, metodología de limpieza, manejo de valores faltantes y atípicos, construcción de atributos derivados, resumen del trabajo de preparación y revisión de formato y redacción del documento.
- **Validación realizada por los estudiantes:** Revisamos las sugerencias generadas por las herramientas de IA. Asimismo, comprobamos mediante el código del cuaderno `2_clean_split.ipynb` que las descripciones metodológicas coincidieran con los procedimientos ejecutados. Comprendemos las decisiones adoptadas y asumimos la responsabilidad por la exactitud, integridad y contenido final del documento.

2.5. Fuentes Bibliográficas y de Datos

Referencias

- [1] Agencia de Protección Ambiental de Estados Unidos (EPA). (2023). *Conceptos básicos sobre el ozono a nivel del suelo*. Recuperado el 20 de agosto de 2026, de <https://www.epa.gov/ground-level-ozone-pollution/ground-level-ozone-basics>
- [2] Romero Lares, F. F. (2024). *Evaluación de la exposición a ozono intramuros y extramuros en cinco zonas de la Ciudad de México durante la temporada de secas-calientes 2023* [Tesis de licenciatura, Universidad Nacional Autónoma de México]. Repositorio Institucional UNAM. <https://ru.dgb.unam.mx/server/api/core/bitstreams/8edfbe22-6c55-4c34-a5d9-c0a7c3f72b95/content>